

ADL HW 1 report

Q1 Data processing

1. Describe how do you use the data for `intent_cls.sh`, `slot_tag.sh`:
 - How do you tokenize the data.
使用 sample code `preprocess_intent.py` / `preprocess_slot.py` to tokenize the data.
 - intent
 - * intent
歷遍所有 intent 並給予每一個不同的 intent 一個唯一的 ID 。
 - * words
以 ' '(空格) 句子分割為 tokens ，並從所有的 token 中選出最常出現的數個 tokens 給予唯一的 ID 。
 - slot
 - * tags
歷遍所有的 tag 並給予每一個不同的 tag 一個獨立的 ID 。
 - * tokens
歷遍所有的 token ，並從中選出最常出現的數個 tokens 給予唯一的 ID 。
 - The pre-trained embedding you used.
glove.840B.300d
2. If you use the sample code, you will need to explain what it does in your own ways to answer Q1.

Q2 Describe your intent classification model

1. Describe

- your model

Input: A sequence of tokens, S

Output: Predict class of the input, K

$\vec{h}_t, \vec{c}_t = LSTM(\vec{w}_t, \vec{h}_{t-1}, \vec{c}_{t-1})$, where w_t is the word embedding of t_{th} token in sequence S.

$\vec{v} = softmax(A\vec{h}_n)$, where A represents a full connected layer and $n = |S|-1$.

$K = \max_{0 \leq i < m} v_i$, where v_i is the i_{th} element of \vec{v} and m is the number of classes.

- performance of your model. (public score on kaggle)
0.87644
- the loss function you used.
Cross entropy
- The optimization algorithm (e.g. Adam), learning rate and batch size.
Optimization algorithm: Adam learning rate: 10^{-5} batch size: 128

Q3 Describe your slot tagging model

1. Describe

- your model
Input: A sequence of tokens, S
Output: A sequence of tags, T
 $\vec{h}_t = GRU(\vec{w}_t, \vec{h}_{t-1}, \vec{c}_{t-1})$, where w_t is the word embedding of t_{th} token of sequence S.
 $\vec{v}_t = softmax(A\vec{h}_t) \forall t \in [0, n]$, where A represents a full connected layer and $n = |S|$.
 $t_i = \max_{0 \leq i < m} v_i^t$, where v_i^t is the i_{th} element of \vec{v}_t and m is the number of classes of tag.
 $T = [t_i \mid \forall i \in [0, n]]$, where $n = |S|$.
- performance of your model. (public score on kaggle)
0.73887
- the loss function you used.
Cross entropy
- The optimization algorithm (e.g. Adam), learning rate and batch size.
Optimization algorithm: AdamW
learning rate: 10^{-3}
batch size: 128

Q4 Sequence Tagging Evaluation

- Please use sequeval to evaluate your model in Q3 on validation set and report `classification_report(scheme=IOB2, mode='strict')`.

	precision	recall	f1-score	support
date	0.73	0.71	0.72	206
first_name	0.90	0.81	0.86	102
last_name	0.81	0.67	0.73	78
people	0.73	0.73	0.73	238
time	0.83	0.86	0.84	218
micro avg	0.78	0.76	0.77	842
macro avg	0.80	0.76	0.78	842
weighted avg	0.78	0.76	0.77	842

- Explain the differences between the evaluation method in sequeval, token accuracy, and joint accuracy.
 - sequeval: 比較每個 tag 出來的片段，並計算片段預測的正確率。
 - token accuracy: 以 token 為單位計算正確率。
 - joint accuracy: 以句子為單位，只要句子中出現任何錯誤就被視為是錯誤的。

Q5 Compare with different configurations

- Please try to improve your baseline method (in Q2 or Q3) with different configuration (includes but not limited to different number of layers, hidden dimension, GRU/LSTM/RNN) and EXPLAIN how does this affects your performance / speed of convergence / ...
- Some possible BONUS tricks that you can try: multi-tasking, few-shot learning, zero-shot learning, CRF, CNN-BiLSTM
- This question will be grade by the completeness of your experiments and your findings.

主要嘗試調整 RNN 模型，hidden size 以及 num layers 。

RNN 使用了 LSTM 與 GRU 兩種，hidden size 嘗試了 400, 512, 600 三種設定，num layers 則測試了 2 與 4 層。

每種設定分別紀錄三種參數: loss, joint accuracy, token accuracy 。再接下來的圖表中分別紀錄為 loss, acc, token_acc 。

接下來會將 joint accuracy 簡稱為 accuracy 。

嘗試後，發現最好的設定是:

- RNN: GRU
- hidden size: 600
- num layers: 2




Figure 1: best eval

在此設定下，可以在 evaluation set 達到 79.4% 的 accuracy 。

然而，在 kaggle 的 public score 中只獲得 76% 的 accuracy 。

使用下面的設定:

- RNN: GRU
- hidden size: 512
- num layers: 2




Figure 2: best kaggle

則可以在 kaggle 的 public score 中獲得 77.9% 的 accuracy 。

其他實驗的結果如下，圖片的命名方式為 {RNN}_{hidden size}_{num layers} 。




Figure 3: LSTM_400_4

簡單總結，可以發現 GRU 的整體表現優於 LSTM 。且當 hidden size 過小時，accuracy 會無法提昇，推測是模型的複雜度不夠所導致。此外 num layers 使用 2 層可以達到較佳得效果。當 hidden size 與 num layers 過大時反而會對 accuracy 造成影響。




Figure 4: LSTM_512_2




Figure 5: LSTM_512_4




Figure 6: LSTM_600_2




Figure 7: GRU_400_2




Figure 8: GRU_400_4




Figure 9: GRU_512_4




Figure 10: GRU_600_2




Figure 11: GRU_600_4

最後，透過 token accuracy 可以觀察到一個有趣的現象。幾乎在所有設定下，token accuracy 在訓練初期就可以達到不錯的成績，然而 joint accuracy 並未有相應的高度。

推測是錯誤的 token 分散在不同 sequence 中，進而導致此現象。

然而，使用 cross entropy 只單純的比對各個 token 的正確性，無法有效的表達 joint accuracy 的正確率。也許可以針對此問題設計 loss function 來解決。